大语言模型遗忘：效果、能力保留与鲁棒性

MSBD 5018 小组项目提案 | 2026 年秋季 | 中文对照版

任务与意义

删除训练资料的源文件后，语言模型仍可能保留相关信息。选择性遗忘旨在减少指定资料的影响，同时保留有用知识，可用于数据撤回和模型维护。基于 TOFU [1] 与 OpenUnlearning [2]，我们拟轻量复现并实证分析遗忘效果、能力保留及提示变化鲁棒性之间的权衡。实验使用虚构作者问答作为可控代理任务，不声称已验证真实隐私或版权资料的彻底删除。

研究问题与方法

我们关注：（1）固定资源预算下，哪些方法具有更好的遗忘与能力保留平衡？（2）保留作者表现更好，是否意味着整体知识能力保留更好？（3）表面遗忘后，改变提示方式能否再次套出相关事实？实验从已学习 4,000 条问答的 TOFU 微调模型 Llama-3.2-1B-Instruct 出发，forget01 指定 40 条遗忘，其余 3,960 条构成保留池。未遗忘模型是基线，官方仅保留资料模型的评价记录作为明确标注的导入参照。

核心比较拟包含梯度上升 GA、梯度差分 GD、负偏好优化 NPO 和无需参照模型的 SimNPO。GA/GD 已完成；NPO/SimNPO 将先做资源检查。表征误导方法 RMU 作为可选第五种方法，其参照模型、中间激活及参数选择方式需额外适配，并将单独报告可训练参数预算。项目比较已有目标函数，不宣称提出新遗忘算法。

在方法兼容时，固定模型起点、数据划分、处理文本、样本抽取、学习率、有效批大小及更新预算，记录各方法系数和参数量。16 GB Mac 已通过 CPU/磁盘承载 FP32 优化器状态和依次反向传播完成 GA/GD 全参数训练。后续不会用 LoRA 结果替代这些基线；若有减少可训练参数的实验，将另列比较。Windows/CUDA 尚未验证。

评价与初步可行性

核心评价使用全部 657 题：40 道遗忘题、400 道保留作者题、100 道真实作者题及 117 道世界知识题。报告遗忘质量 FQ（与仅保留资料参照作 KS 检验的 p 值）、模型效用 MU（九项非遗忘分数的调和平均值）、回答案例及资源消耗。FQ 不是准确率，也不证明不可逆遗忘。以下为已完成的种子 0 结果；每种训练方法均执行 10 次参数更新：

模型	遗忘质量 FQ	模型效用 MU
未遗忘模型	0.0143	0.5993
GA	0.4046	0.4019
GD	0.7659	0.3887

两种方法 FQ 均提高，但 GD 总体 MU 未优于 GA，与已发表对照不同，说明仅部分复现，也促使我们分析能力分量。计划测试 GD 保留权重 {0.5, 1, 2}，对核心 GA/GD 补充种子 {0, 1, 2}，并根据实际设置绘制遗忘与效用关系。另用直接、上下文、角色扮演、指令挑战四类提示，对相同遗忘问题及对应保留对照做鲁棒性测试。答案重合度仅用于筛查，是否恢复事实须人工复核。以上扩展尚未完成，不作为已有结果。

交付与协作

四位组员共同承担文献与数据、方法与训练、评价与鲁棒性、分析与展示，交叉审阅。计划 11 月 17 日前提交主要结果，12 月 9 日前提交 ACL 格式报告、代码与数据。交付固定配置、原始回答、权衡图及可复现的对照展示。

参考文献

[1] Maini 等（2024）. TOFU: A Task of Fictitious Unlearning for LLMs. arXiv:2401.06121.

[2] Dorna 等（2025）. OpenUnlearning: Accelerating LLM Unlearning via Unified Benchmarking of Methods and Metrics. arXiv:2506.12618.